

INFORME TÉCNICO: TRABAJO PRÁCTICO INTEGRADOR

Diseño de la Capa de Datos para un Sistema RAG de Documentación Técnica

Asignatura: Bases de Datos para Inteligencia Artificial

Docente: Martín Lacheski

Año: 2026

Integrantes del Grupo: Andrea Ferenaz, Mauro Virgilio Blanc, Juan Pablo Imbrogno

1. Descripción del Caso de Uso

1.1 Contexto y Problema a Resolver

La organización cuenta con un volumen considerable de documentación técnica — manuales de procedimiento, especificaciones de maquinaria, normativas de seguridad e instructivos operativos— distribuida de forma heterogénea en archivos PDF e históricos. El proceso manual de búsqueda de información genera cuellos de botella en la resolución de incidentes operativos.

Para resolver este problema, se diseña la infraestructura de datos para un sistema de **Generación Aumentada por Recuperación (RAG - *Retrieval-Augmented Generation*)**. La solución permite ingestar la documentación, procesarla en fragmentos consultables (*chunks*), vectorizarlos y permitir que los usuarios realicen consultas en lenguaje natural mediante un Modelo de Lenguaje (LLM). El sistema recupera los fragmentos con mayor similitud semántica y los entrega como contexto al LLM, garantizando respuestas precisas y citando las fuentes utilizadas.

1.2 Usuarios y Roles Principales

- **Técnico / Ingeniero (Lector):** Consulta dudas operativas en lenguaje natural. Solo debe acceder a la información autorizada para su área y nivel jerárquico.
- **Administrador de Documentación (Editor):** Carga nuevos documentos, actualiza versiones, define clasificaciones y retira documentación obsoleta.
- **Auditor / Supervisor (Auditor):** Revisa el historial de consultas, evalúa las fuentes recuperadas y analiza métricas de precisión y trazabilidad de las respuestas generadas por la IA.

1.3 Decisiones de Diseño Críticas y Gestión de Riesgos

- **Automatización del Ciclo de Vida e Ingesta Continuous:** Para evitar procesos manuales o barridos batch ineficientes, el sistema implementa una ingesta asíncrona basada en eventos sobre el sistema de archivos mediante *watchdog*.

- **Aislamiento y Filtrado de Seguridad (Fuga de Información):** El mayor riesgo en sistemas RAG corporativos es el retorno no autorizado de fragmentos confidenciales. El diseño aborda esto integrando metadatos de seguridad directamente en las consultas vectoriales y aplicando políticas a nivel de base de datos relacional (Row Level Security).
- **Trazabilidad y Auditoría:** La base de datos registra explícitamente qué versión de qué documento y qué fragmentos específicos se utilizaron para responder cada consulta.
- **Control de Obsolescencia:** Un documento marcado como "archivado" o "obsoleto" inhabilita automáticamente sus fragmentos vectoriales en el pipeline de búsqueda RAG.

2. Relevamiento y Clasificación de Datos

Para alimentar el pipeline RAG y la capa operacional de soporte, los datos se clasifican según su naturaleza y nivel de estructuración:

Tipo de Dato	Descripción y Ejemplos	Formato / Almacenamiento
No Estructurados	Archivos PDF originales depositados en el directorio fuente (data/ejemplos/archivos_fuente/).	Sistema de Archivos Local / Almacenamiento de Objetos.
Semiestructurados	Fragmentos de texto (<i>chunks</i>) extraídos por el pipeline de ingesta, metadatos de ubicación (página, posición) y respuestas generadas en formato JSON.	Tipos <code>JSONB</code> en PostgreSQL.
Estructurados (Operacionales)	Entidades del dominio: Usuarios, Áreas, Categorías, Documentos y Versiones.	Tablas Relacionales (PostgreSQL).
Estructurados (Vectoriales)	Representaciones matemáticas (<i>embeddings</i>) de 768 dimensiones de cada fragmento de texto.	Tipo <code>vector(768)</code> mediante la extensión <code>pgvector</code> .
Datos de Auditoría	Logs de consultas realizadas por usuarios, tiempo de respuesta, prompt emitido y relación M:N de fragmentos citados.	Tablas relacionales con restricciones de clave foránea.

3. Modelo Conceptual

El dominio se modeló mediante un Diagrama Entidad-Relación (DER) que independiza la lógica del negocio de la implementación tecnológica final.

3.1 Entidades y Atributos Principales

- **AREA:** `area_id` (PK), `nombre_area`, `codigo_interno`.
- **USUARIO:** `usuario_id` (PK), `nombre`, `email`, `area_id` (FK), `nivel_acceso`.
- **CATEGORIA:** `categoria_id` (PK), `nombre_categoria`, `descripcion`.
- **DOCUMENTO:** `documento_id` (PK), `titulo`, `estado` (Vigente/En Revisión/Archivado), `nivel_acceso_requerido`, `area_id` (FK), `categoria_id` (FK).
- **VERSION_DOCUMENTO:** `version_id` (PK), `documento_id` (FK), `numero_version`, `fecha_publicacion`, `url_archivo_origen`, `es_version_activa` (Boolean).
- **FRAGMENTO (Chunk):** `fragmento_id` (PK), `version_id` (FK), `numero_secuencia`, `contenido_texto`, `embedding_vector` (Vector), `metadatos_json` (JSONB).
- **CONSULTA_RAG:** `consulta_id` (PK), `usuario_id` (FK), `pregunta_texto`, `respuesta_ia`, `fecha_hora`.
- **FUENTE_CONSULTA (Relación M:N):** `consulta_id` (FK), `fragmento_id` (FK), `score_similitud`.

4. Modelo Lógico y Selección Tecnológica

4.1 Justificación de la Selección Tecnológica

Se seleccionó **PostgreSQL con la extensión pgvector** como motor unificado de la solución, complementado con un pipeline de ingesta en **Python** (`ingesta_automatica.py`) utilizando `watchdog` y `psycopg2`.

Razones de la elección:

1. **Unificación de Arquitectura (Hybrid Search):** Evita la necesidad de mantener dos bases de datos separadas (una relacional para usuarios/permisos y una vectorial dedicada como Pinecone/ChromaDB), eliminando el problema de sincronización entre dos sistemas de almacenamiento distintos (*Dual-Database Sync Problem*).
2. **Modelo Local de Alta Precisión (Nomic v1.5):** Genera embeddings de 768 dimensiones nativas. Ofrece un contexto amplio de 2048 tokens y rendimiento competitivo frente a modelos propietarios de API, sin incurrir en costos por volumen ni fuga de datos a servidores externos.
3. **Consistencia ACID y Filtrado Unificado:** Permite ejecutar la búsqueda de similitud semántica por coseno y el filtrado estricto de seguridad relacional (`WHERE area_id = ...`) en una sola consulta SQL atómica.
4. **Ingesta Reactiva e Inmediata:** La librería `watchdog` monitorea eventos del sistema de archivos en tiempo real, permitiendo disparar el procesamiento ETL (chunking + vectorización) apenas se deposita un PDF, reduciendo la latencia de disponibilidad del documento (*time-to-ingest*).

5. **Soporte de Metadatos Semiestructurados:** El tipo de dato nativo `JSONB` de PostgreSQL permite almacenar y filtrar metadatos cambiantes de cada fragmento (página, párrafo, tags) con soporte de índices GIN.

5. Decisiones de Normalización y Diseño

- **Normalización Relacional (Hasta 3FN):** La capa operacional (`USUARIO`, `DOCUMENTO`, `VERSION_DOCUMENTO`, `AREA`) está estrictamente normalizada en Tercera Forma Normal para garantizar la integridad referencial, eliminar redundancias y prevenir anomalías de actualización en datos críticos de seguridad.
- **Desacople de Ciclo de Vida de Documentos:** La separación entre `DOCUMENTO` y `VERSION_DOCUMENTO` permite mantener un historial completo de cambios mientras se garantiza que las consultas RAG solo consideren la versión activa (`es_version_activa = TRUE`).
- **Desnormalización Controlada en Fragmentos:** En la tabla `FRAGMENTO`, se duplica de manera calculada el campo de metadatos en un objeto `JSONB`. Esto optimiza la velocidad de lectura durante el pipeline de recuperación del LLM sin requerir *joins* complejos en el momento de la consulta vectorial de baja latencia.

6. Modelo Físico e Implementación Mínima

El esquema físico se implementó mediante DDL en PostgreSQL, habilitando la extensión `pgvector`.

SQL

```
-- Habilitación de la extensión vectorial
CREATE EXTENSION IF NOT EXISTS vector;

-- Tabla de Áreas
CREATE TABLE areas (
    area_id SERIAL PRIMARY KEY,
    nombre_area VARCHAR(100) NOT NULL,
    codigo_interno VARCHAR(20) UNIQUE NOT NULL
);

-- Tabla de Usuarios
CREATE TABLE usuarios (
    usuario_id SERIAL PRIMARY KEY,
    nombre VARCHAR(100) NOT NULL,
    email VARCHAR(100) UNIQUE NOT NULL,
    area_id INT NOT NULL REFERENCES areas(area_id),
    nivel_acceso VARCHAR(50) NOT NULL DEFAULT 'Tecnico_Basico'
);

-- Tabla de Documentos
CREATE TABLE documentos (
    documento_id SERIAL PRIMARY KEY,
    titulo VARCHAR(255) NOT NULL,
    estado VARCHAR(20) CHECK (estado IN ('vigente', 'en_revision',
'archivado')) DEFAULT 'vigente',
```

```

        nivel_acceso_requerido VARCHAR(50) NOT NULL,
        area_id INT NOT NULL REFERENCES areas(area_id)
    );

-- Tabla de Versiones
CREATE TABLE versiones_documento (
    version_id SERIAL PRIMARY KEY,
    documento_id INT NOT NULL REFERENCES documentos(documento_id),
    numero_version VARCHAR(20) NOT NULL,
    fecha_publicacion TIMESTAMP WITH TIME ZONE DEFAULT CURRENT_TIMESTAMP,
    url_archivo_origen VARCHAR(500) NOT NULL,
    es_activa BOOLEAN DEFAULT true
);

-- Tabla de Fragmentos (Chunks) con soporte Vectorial
CREATE TABLE fragmentos (
    fragmento_id SERIAL PRIMARY KEY,
    version_id INT NOT NULL REFERENCES versiones_documento(version_id),
    numero_secuencia INT NOT NULL,
    contenido_texto TEXT NOT NULL,
    embedding vector(768), -- Dimensión nativa para nomic-embed-text-v1.5
    metadatos JSONB
);

-- Tabla de Consultas RAG
CREATE TABLE consultas_rag (
    consulta_id SERIAL PRIMARY KEY,
    usuario_id INT NOT NULL REFERENCES usuarios(usuario_id),
    pregunta_texto TEXT NOT NULL,
    respuesta_ia TEXT NOT NULL,
    fecha_hora TIMESTAMP WITH TIME ZONE DEFAULT CURRENT_TIMESTAMP
);

-- Tabla Intermedia para Fuentes (Trazabilidad M:N)
CREATE TABLE fuentes_consulta (
    consulta_id INT REFERENCES consultas_rag(consulta_id) ON DELETE
    CASCADE,
    fragmento_id INT REFERENCES fragmentos(fragmento_id),
    score_similitud FLOAT NOT NULL,
    PRIMARY KEY (consulta_id, fragmento_id)
);

```

7. Consultas Representativas

A continuación se presentan las consultas SQL clave que resuelven la lógica de negocio, optimización y trazabilidad del sistema.

Consulta 1: Búsqueda RAG por Similitud Coseno con Filtro de Seguridad Integrado

- Pregunta de negocio:** *"Buscar los 3 fragmentos de texto más parecidos a la pregunta del usuario '¿Cómo actuar ante una vibración excesiva en la turbina?', garantizando que el usuario solo acceda a documentos de su área y con estado vigente."*

SQL

```
SELECT
    f.fragmento_id,
    d.titulo AS documento_titulo,
    f.contenido_texto,
    f.metadatos->>'pagina_pdf' AS pagina,
    1 - (f.embedding <=> '[0.0142, -0.0831, 0.3124, ...]':vector) AS
similitud_coseno
FROM fragmentos f
JOIN versiones_documento v ON f.version_id = v.version_id
JOIN documentos d ON v.documento_id = d.documento_id
JOIN usuarios u ON u.usuario_id = 10 -- ID del usuario que consulta
WHERE v.es_activa = TRUE
    AND d.estado = 'vigente'
    AND d.area_id = u.area_id -- Filtro de Aislamiento
ORDER BY f.embedding <=> '[0.0142, -0.0831, 0.3124, ...]':vector ASC
LIMIT 3;
```

Consulta 2: Auditoría y Trazabilidad de Fuentes por Consulta

- **Pregunta de negocio:** *"Dado el ID de una consulta generada por la IA, determinar qué documentos, versiones y fragmentos exactos fueron utilizados para construir la respuesta."*

SQL

```
SELECT
    c.consulta_id,
    c.pregunta_texto,
    c.respuesta_ia,
    d.titulo AS documento_fuente,
    v.numero_version,
    f.numero_secuencia AS chunk_numero,
    fc.score_similitud
FROM consultas_rag c
JOIN fuentes_consulta fc ON c.consulta_id = fc.consulta_id
JOIN fragmentos f ON fc.fragmento_id = f.fragmento_id
JOIN versiones_documento v ON f.version_id = v.version_id
JOIN documentos d ON v.documento_id = d.documento_id
WHERE c.consulta_id = 5001
ORDER BY fc.score_similitud DESC;
```

Consulta 3: Reporte Analítico de Documentos más Citados por la IA

- **Pregunta de negocio:** *"¿Cuáles son los 5 documentos técnicos más consultados y citados por el sistema RAG en el último mes?"*

SQL

```
SELECT
    d.documento_id,
    d.titulo,
    COUNT(fc.fragmento_id) AS total_citas
```

```

FROM fuentes_consulta fc
JOIN fragmentos f ON fc.fragmento_id = f.fragmento_id
JOIN versiones_documento v ON f.version_id = v.version_id
JOIN documentos d ON v.documento_id = d.documento_id
JOIN consultas_rag c ON fc.consulta_id = c.consulta_id
WHERE c.fecha_hora >= NOW() - INTERVAL '30 days'
GROUP BY d.documento_id, d.titulo
ORDER BY total_citas DESC
LIMIT 5;

```

Consulta 4: Detección de Documentos Obsoletos con Fragmentos Activos (Control de Integridad)

- **Pregunta de negocio:** *"Listar las versiones de documentos marcadas como inactivas o archivadas que aún poseen fragmentos indexados, para mantenimiento del pipeline."*

SQL

```

SELECT
    d.titulo,
    v.numero_version,
    d.estado,
    COUNT(f.fragmento_id) AS cantidad_chunks_asociados
FROM documentos d
JOIN versiones_documento v ON d.documento_id = v.documento_id
JOIN fragmentos f ON v.version_id = f.version_id
WHERE d.estado = 'archivado' OR v.es_activa = FALSE
GROUP BY d.titulo, v.numero_version, d.estado;

```

8. Estrategia de Optimización e Índices

Para garantizar tiempos de respuesta en milisegundos en búsquedas vectoriales sobre miles de fragmentos, se implementa un índice vectorial **HNSW (Hierarchical Navigable Small World)** usando la distancia de coseno, combinado con índices B-Tree tradicionales sobre los campos relacionales de filtrado frecuente:

SQL

```

-- Índice vectorial HNSW para distancia coseno
CREATE INDEX idx_fragmentos_embedding_hnsw
ON fragmentos
USING hnsw (embedding vector_cosine_ops)
WITH (m = 16, ef_construction = 64);

-- Índice GIN sobre metadatos JSONB
CREATE INDEX idx_fragmentos_metadatos_gin
ON fragmentos
USING gin (metadatos);


-- Índice B-Tree para optimizar los Joins relacionales y filtros de área
CREATE INDEX idx_documentos_area_estado
ON documentos (area_id, estado);

```

```
-- Índice Parcial: Solo indexa los registros que cumplen la condición
CREATE INDEX idx_versiones_activas ON versiones_documento (documento_id)
WHERE es_activa = TRUE;
```

9. Arquitectura de Datos e Ingesta Automática

El flujo de información se organiza en 4 capas secuenciales , incorporando el pipeline reactivo de ingesta continua:



10. Seguridad, Permisos y Escalabilidad

- **Seguridad y Aislamiento (Multi-tenant por Area):** La seguridad se aplica mediante filtrado obligatorio en la cláusula WHERE del motor SQL combinando `area_id` y `nivel_acceso_requerido`. Adicionalmente, se propone la activación de Row Level Security (RLS) en PostgreSQL para limitar las filas retornadas según el perfil o nivel del usuario autenticado.
- **Escalabilidad del Pipeline de Ingesta:** La utilización de `watchdog` permite desacoplar la carga de documentos de las operaciones de consulta del usuario.
- **Particionado:** La tabla de fragmentos se puede particionar por rango o por lista según la categoría o el área del documento para optimizar el escaneo de índices.
- **Mantenimiento de Índices:** Monitoreo periódico del parámetro `ef_search` del índice HNSW para balancear el rendimiento de CPU frente al recall de la búsqueda semántica.

11. Conclusiones

El diseño desarrollado demuestra que una solución de datos para Inteligencia Artificial no requiere necesariamente desacoplar los motores de búsqueda de la base de datos operacional.

La integración de **PostgreSQL con pgvector** y una **canalización automatizada de ingesta en Python (watchdog + Nomic v1.5)** permite resolver la carga de documentos y la recuperación semántica propia de la arquitectura RAG, manteniendo al mismo tiempo estrictos controles de integridad relacional, seguridad por niveles de acceso y trazabilidad completa de las fuentes de información utilizadas por el LLM